

2025 年（第 18 届）

中国大学生计算机设计大赛

人工智能实践赛作品报告

基于改进 ConvNeXt 的多类别

皮肤疾病智能分类系统

作品编号： _____

作品名称： _____

填写日期： _____

填写说明：

- 1、 本文档适用于人工智能挑战赛预选赛；

- 2、 尽管预选赛仅完成部分工作，但是本文档需要针对决赛做出方案设计；
- 3、 正文、标题格式已经在本文中设定，请勿修改；
- 4、 本文档应结构清晰，突出重点，适当配合图表，描述准确，不易冗长拖沓；
- 5、 提交文档时，以 **PDF** 格式提交；
- 6、 本文档内容是正式参赛内容的组成部分，务必真实填写。如不属实，将导致奖项等级降低甚至终止本作品参加比赛。

目录

1	作品概述	1
1.1	研究背景	1
1.2	作品目标	1
1.3	主要工作	2
2	问题分析	3
2.1	问题来源	3
2.2	现有解决方案	3
2.3	本作品要解决的痛点问题	4
2.4	解决问题的思路	4
3	技术方案	5
3.1	整体架构	5
3.2	核心算法	5
3.2.1	基线模型: ConvNeXt-Tiny	5
3.2.2	改进一: ConvNeXt V2 (GRN 全局响应归一化)	6
3.2.3	改进二: 广义均值池化 (GeM Pooling)	6
3.2.4	改进三: 指数滑动平均 (EMA)	6
3.3	训练配置	7
4	系统实现	8
4.1	开发环境	8
4.2	项目结构	8
4.3	核心模块实现	9
4.3.1	GeM Pooling 模块	9
4.3.2	EMA 模块	9
4.3.3	Grad-CAM 注意力可视化	10
4.3.4	流式 AI 报告	10
4.4	关键技术难点与解决方案	11
5	测试分析	12
5.1	实验设置	12
5.2	主要结果	12
5.3	混淆矩阵分析	13
5.4	ROC 曲线分析	14

5.5	Per-Class 性能对比	14
5.6	高风险类别专项分析	15
5.7	注意力可视化对比	15
5.8	推理效率	16
6	作品总结	17
6.1	作品特色与创新点	17
6.2	应用推广	18
6.2.1	应用场景	18
6.2.2	推广路径	18
6.3	作品展望	18
6.3.1	短期改进（3-6 个月）	18
6.3.2	中长期规划（6-18 个月）	19
	参考文献	20

1 作品概述

1.1 研究背景

皮肤病是全球疾病负担的重要组成部分。据世界卫生组织统计，全球约有 9 亿人患有各类皮肤疾病，其中皮肤癌发病率在过去 30 年间持续上升。传统皮肤疾病诊断依赖皮肤科医生的目视检查和皮肤镜检查，然而全球范围内皮肤科医生分布极不均衡——非洲部分地区每 100 万人口仅有不到 1 名皮肤科医生，我国基层医疗机构同样面临皮肤科医生严重短缺的问题。

深度学习技术在医学图像分析领域已取得显著进展。从 AlexNet 到 ResNet，再到 Vision Transformer，图像分类模型的准确率不断提升。然而，将通用模型直接应用于皮肤疾病分类仍面临三个核心挑战：（1）细粒度识别——不同皮肤病在外观上高度相似，类间差异极小；（2）类内差异大——同一疾病在不同患者、不同部位、不同阶段的形态差异显著；（3）数据不均衡——常见病与罕见病的样本量差异可达 6 倍以上。

1.2 作品目标

本作品旨在构建一个基于改进 ConvNeXt 架构的 22 类皮肤疾病智能辅助分类系统，实现以下目标：

1. **高准确率分类**：在包含 15,444 张图像的公开数据集上，达到 82% 以上的验证准确率。
2. **可解释性分析**：通过 Grad-CAM 注意力热力图可视化模型关注的病灶区域，为临床医生提供判断依据。
3. **大模型辅助咨询**：接入大语言模型 API，基于分类结果生成疾病概述、治疗建议等医学报告，并提供多轮对话咨询功能。
4. **完整实验对比**：设计消融实验，系统评估各组件的独立贡献，为后续研究提供参考。

1.3 主要工作

表 1.1 主要工作内容汇总

工作内容	说明
基线模型搭建	ConvNeXt-Tiny + 全局平均池化，验证集准确率 79.80%
骨干网络升级	ConvNeXt V1 → ConvNeXt V2，引入全局响应归一化（GRN）
池化策略改进	全局平均池化 → 广义均值池化（GeM Pooling），可学习参数 p
权重优化	引入指数滑动平均（EMA），decay=0.999
消融实验	对比基线 vs 改进模型的性能差异，分析各组件贡献
可解释性	实现 Grad-CAM 注意力可视化，并排对比基线/改进模型的关 注区域差异
Web 应用	基于 Flask + 原生前端构建完整交互系统，支持流式 AI 报告 和对话
ONNX 部署	导出 ONNX 模型，支持跨平台推理部署

2 问题分析

2.1 问题来源

皮肤疾病的自动分类是人工智能医学影像领域的重要研究方向。目前存在以下实际问题：

- 1. **医疗资源不均：**我国基层医疗机构皮肤科医生严重不足，许多皮肤病患者无法获得及时、准确的诊断。
- 2. **诊断主观性强：**不同医生对同一皮损的诊断可能存在差异，尤其在不典型病例中。
- 3. **筛查效率低下：**大规模皮肤癌筛查中，医生需要逐一检查每张图像，工作量大且容易出现疲劳性误判。
- 4. **患者缺乏医学知识：**普通民众难以判断皮损的严重程度，可能延误就医时机。

2.2 现有解决方案

表 2.1 现有解决方案对比

方案	代表方法	优点	不足
人工诊断	皮肤科医生目视检查 + 皮肤镜	准确率高, 可结合临床经验	效率低, 受地域和资源限制
CNN 分类	ResNet / Efficient-Net + 皮肤病数据集	自动化程度高, 准确率 70-80%	细粒度分类能力有限
Vision Transformer	ViT / Swin Transformer	全局感受野, 细粒度表现好	数据需求大, 推理慢
多模态融合	图像 + 临床元数据	信息更全面	元数据获取困难, 标注成本高

2.3 本作品要解决的痛点问题

1. **细粒度识别困难**：部分皮肤病因视觉特征高度相似（如光化性角化病 vs 脂溢性角化病），传统 CNN 模型对此类细粒度分类的区分能力不足。本作品通过 GRN（全局响应归一化）增强特征多样性，GeM Pooling 聚焦判别性区域，系统性提升细粒度分类能力。
2. **特征坍缩问题**：深层 CNN 在训练过程中容易出现”特征坍缩”——各通道特征趋于高度相关，有效特征维度降低。ConvNeXt V2 引入的 GRN 层直接针对此问题设计。
3. **池化策略固化的局限**：传统全局平均池化对所有空间位置赋予相等权重，无法自动聚焦病灶关键区域。本作品采用可学习参数 p 的 GeM Pooling，让模型在训练中自动发现最优池化策略。
4. **缺乏可交互的辅助诊断工具**：现有研究多为离线模型评估，缺乏可实际使用的交互系统。本作品构建了完整的 Web 应用，集成分类、可解释性分析、大模型辅助咨询等功能。

2.4 解决问题的思路

表 2.2 问题与方案映射关系

问题	方案	效果
细粒度识别难	ConvNeXt V2 GRN	增强特征多样性
特征坍缩	GRN 归一化	抑制通道相关性
池化策略固化	GeM Pooling	可学习特征聚合
参数波动	EMA 平滑	提升泛化能力
缺乏交互工具	Flask + SSE	Web 应用 + AI 对话

3 技术方案

3.1 整体架构

系统架构分为四个层次：

1. **应用层 (Web UI)**：基于 Flask + HTML/CSS/JS + SSE 流式传输构建的前端交互界面。
2. **服务层 (AI 增强)**：提供 Grad-CAM 注意力可视化和大模型 API 服务（疾病报告 + 对话）。
3. **推理层 (模型)**：ConvNeXtV2 + GeM Pooling + EMA，支持 PyTorch 和 ONNX 两种推理方式。
4. **数据层**：Skin Disease Dataset，包含 15,444 张图像，共 22 个类别。

3.2 核心算法

3.2.1 基线模型：ConvNeXt-Tiny

ConvNeXt (Liu et al., CVPR 2022) 通过系统性地将 Transformer 设计理念引入 CNN，实现了与 Vision Transformer 相当的性能。ConvNeXt-Tiny 参数规模约 28M，适合医学图像分类任务。

结构参数：

- 四个 Stage，通道数 [96, 192, 384, 768]，block 数 [3, 3, 9, 3]
- 分类头：AdaptiveAvgPool2d → LayerNorm → Linear(768, 22)

3.2.2 改进一：ConvNeXt V2 (GRN 全局响应归一化)

ConvNeXt V2 (Woo et al., CVPR 2023) 在每个 block 末尾插入 GRN 层：

$$\text{GRN}(X_i) = \gamma \cdot \frac{X_i}{\sqrt{\|X_i\|^2 + \epsilon}} + \beta \quad (3.1)$$

GRN 通过 L2 归一化强制各通道保持多样性，抑制深层网络中的特征坍塌。其中 γ 和 β 为可学习参数， ϵ 为数值稳定性常数。

3.2.3 改进二：广义均值池化（GeM Pooling）

广义均值池化（Radenović et al., TPAMI 2018）的公式如下：

$$f^{(g)} = \left[\frac{1}{|\Omega|} \sum_{x \in \Omega} x^p \right]^{\frac{1}{p}} \quad (3.2)$$

其中：

- $p = 1$ ：退化为平均池化（GAP）
- $p \rightarrow \infty$ ：逼近最大池化（GMP）
- $p > 1$ ：赋予高响应区域更大权重

关键设计决策： p 初始化为 **1.0**（非文献默认 3.0）。实验发现 $p_{init} = 3.0$ 在训练初期导致严重收敛困难（首轮验证准确率仅 5.9%）， $p_{init} = 1.0$ 让模型从 GAP 起步，训练中 p 自动增长以聚焦判别性区域。

3.2.4 改进三：指数滑动平均（EMA）

指数滑动平均（Polyak & Juditsky, 1992）维护模型参数的滑动平均副本：

$$\theta_{\text{shadow}}^{(t)} = 0.999 \cdot \theta_{\text{shadow}}^{(t-1)} + 0.001 \cdot \theta^{(t)} \quad (3.3)$$

EMA 在推理时使用 shadow 权重，等效窗口约 1,000 步，在不增加推理开销的前提下提升泛化能力。

3.3 训练配置

表 3.1 训练超参数配置

超参数	值	说明
优化器	AdamW	解耦权重衰减
学习率	1e-4	余弦预热重启调度
权重衰减	0.05	L2 正则化
损失函数	CrossEntropy + Label Smoothing ($\epsilon=0.1$)	缓解过拟合，处理长尾分布
批量大小	32	适合 28M 参数量
最大 Epoch	50	Early Stopping (patience=10)
混合精度	AMP (GradScaler)	加速训练，节省显存
数据增强	RandCrop + Flip + Rotation + ColorJitter	7 种增强策略
输入尺寸	224×224	ImageNet 标准

4 系统实现

4.1 开发环境

表 4.1 开发环境配置

组件	版本/型号
操作系统	macOS / Windows
编程语言	Python 3.14
深度学习框架	PyTorch 2.x
模型库	timm 0.9.x
Web 框架	Flask 3.x
图像处理	OpenCV, PIL
硬件	Apple M5 (MPS) / NVIDIA GPU (CUDA)
大模型 API	OpenAI 兼容接口（支持豆包/GPT-4/本地模型）

4.2 项目结构

```
1 skin_detect/
2 |— train.py           # 训练主脚本，支持消融变体
3 |— detect.py          # 命令行推理脚本
4 |— export_onnx.py     # ONNX 模型导出
5 |— models/
6 |   |— modules.py     # GeM Pooling, EMA,
   MultiScaleHead
7 |— utils/
8 |   |— visualize.py   # 混淆矩阵, ROC曲线, Grad-CAM 可
   视化
9 |— web_app/
10 |   |— app.py         # Flask 后端 (分类/Grad-CAM/LLM/
   SSE)
11 |   |— templates/index.html # 前端页面
12 |   |— static/
13 |       |— style.css  # 样式
14 |       |— app.js     # 前端逻辑 (上传/流式/对话)
```

```

15 |─ runs/
16 |   |─ convnext_tiny/           # 基线模型 (Val Acc 79.80%)
17 |   |   |─ best.pt
18 |   |   |─ *.onnx / *.onnx.data
19 |   |   |─ confusion_matrix.png
20 |   |   |─ roc_curves.png
21 |   |   |─ per_class_metrics.png
22 |   |   └─ training_curves.png
23 |   └─ convnextv2_tiny_GeM_EMA/ # 改进模型 (Val Acc 82.20%)
24 |       └─ ... (同上)
25 |─ TECHNICAL_REPORT.md        # 论文级技术文档
26 |─ INNOVATION.md              # 创新点描述
27 |─ PROJECT_REPORT.md          # 本报告

```

Listing 4.1 项目目录结构

4.3 核心模块实现

4.3.1 GeM Pooling 模块

```

1 class GeMPool(nn.Module):
2     """广义均值池化层，可学习参数 p"""
3     def __init__(self, p_init=1.0):
4         super().__init__()
5         self.p = nn.Parameter(torch.ones(1) * p_init)
6
7     def forward(self, x):
8         # 限制 p 的范围，防止数值不稳定
9         p = self.p.clamp(min=1.0, max=5.0)
10        return x.clamp(min=1e-6).pow(p).mean(dim=(2, 3)).pow(1.0
            / p)

```

Listing 4.2 GeM Pooling 实现代码

4.3.2 EMA 模块

```

1 class ModelEMA:
2     """模型指数滑动平均"""
3     def __init__(self, model, decay=0.999):

```

```

4         self.decay = decay
5         self.shadow = {}
6         for name, param in model.named_parameters():
7             if param.requires_grad:
8                 self.shadow[name] = param.data.clone()
9
10        def update(self, model):
11            """更新 shadow 参数"""
12            for name, param in model.named_parameters():
13                if param.requires_grad:
14                    self.shadow[name].mul_(self.decay).add_(
15                        param.data, alpha=1 - self.decay
16                    )
17
18        def apply_shadow(self, model):
19            """将 shadow 权重应用到模型"""
20            for name, param in model.named_parameters():
21                if param.requires_grad:
22                    param.data.copy_(self.shadow[name])

```

Listing 4.3 EMA 实现代码

4.3.3 Grad-CAM 注意力可视化

通过注册前向/反向 hook 捕获 Stage 4 的特征图和梯度，计算加权激活图，生成病灶区域热力图。同时加载基线和改进模型，并排展示两者的注意力差异。

4.3.4 流式 AI 报告

使用 Server-Sent Events (SSE) 实现大模型 API 的流式传输。客户端通过 AbortController 管理 SSE 连接生命周期，避免多请求阻塞。

4.4 关键技术难点与解决方案

表 4.2 关键技术难点与解决方案

难点	解决方案
GeM p_init 导致训练崩溃	p_init 从 3.0 $\rightarrow$ 1.0, 从 GAP 起步
OpenCV 中文乱码	改用 PIL + 系统 CJK 字体渲染
流式传输连接冲突	AbortController 管理 + SSE 独立通道
旧 checkpoint 不兼容新架构	key 重映射 (backbone. 前缀、head 索引)
ONNX 导出 opset 兼容性	使用 opset 18 + dynamo 导出 + 外部权重

5 测试分析

5.1 实验设置

- 数据集：Skin Disease Dataset，22 类，15,444 张图像（训练 13,898 + 测试 1,546）
- 评估指标：Accuracy, Precision, Recall, F1, AUC, 混淆矩阵
- 对比实验：基线模型（ConvNeXt V1 + AvgPool）vs 改进模型（ConvNeXt V2 + GeM + EMA）

5.2 主要结果

表 5.1 基线模型与改进模型性能对比

指标	基线	改进	提升
验证集准确率	79.80%	82.20%	+2.40%
测试集准确率	80.47%	81.69%	+1.22%
Micro AUC	0.9740	0.9816	+0.0076
Macro F1	0.771	0.801	+3.0%
验证集 Loss	1.222	1.141	-0.081
参数量	27.84M	27.88M	+0.17%




图 5.1 基线模型训练曲线（最优 Epoch 45, Val Acc = 79.80%）




图 5.2 改进模型训练曲线（最优 Epoch 50, Val Acc = 82.20%）

5.3 混淆矩阵分析




图 5.3 验证集混淆矩阵对比（左：基线模型，右：改进模型）

改进模型的对角线更集中，表明分类精度全面提升。Actinic Keratosis $\leftrightarrow$ Seborrheic Keratoses 的跨类混淆有所减少。

5.4 ROC 曲线分析




图 5.4 One-vs-Rest ROC 曲线对比（左：基线 Micro AUC=0.974，右：改进 Micro AUC=0.982）

改进模型在各类别上的 AUC 普遍提升，尤其在中高风险类别（Lupus、Bul-lous）上提升显著。

5.5 Per-Class 性能对比



图 5.5 Per-Class Precision/Recall/F1 指标对比（左：基线模型，右：改进模型）

表 5.2 F1 提升最大的 Top 5 类别

提升最大 Top 5	基线 F1	改进 F1	提升幅度
Lupus（红斑狼疮）	0.688	0.809	+17.6%
Bullous（大疱性皮肤病）	0.713	0.795	+11.5%
Lichen（苔藓）	0.693	0.759	+9.5%
Tinea（癣）	0.719	0.782	+8.8%
Sun/Sunlight Damage	0.660	0.712	+7.9%

5.6 高风险类别专项分析

Skin Cancer（皮肤癌）作为唯一 HIGH 风险类别，其分类性能具有特殊临床意义：

表 5.3 皮肤癌类别性能对比

指标	基线	改进	临床意义
Precision	70.54%	66.40%	假阳性增多
Recall	73.83%	77.57%	假阴性减少（漏诊降低 3.7%）

改进模型以 Precision 下降为代价换取 Recall 提升——在筛查场景中，减少漏诊远比减少误报重要。

5.7 注意力可视化对比

改进模型（V2 + GeM）的 Grad-CAM 热力图相比基线（V1 + Avg）更聚焦于病灶核心区域。GeM Pooling 在训练过程中自动学习关注高判别性区域，注意力分布更紧凑，边界更清晰。




图 5.6 测试集混淆矩阵对比（左：基线模型，右：改进模型）

5.8 推理效率

表 5.4 模型推理效率对比

模型	参数量	ONNX 大小	单图推理 (CPU)
Baseline	27.84M	111 MB	45ms
Improved	27.88M	112 MB	48ms

改进模型参数量仅增加 0.17%，推理时间增加约 6%（GRN 层额外计算），在可接受范围内。

6 作品总结

6.1 作品特色与创新点

创新点一：GeM Pooling 初始化策略改进

传统 GeM Pooling 默认 $p_{init} = 3.0$ ，本文发现该设置在医学图像分类任务中导致严重收敛困难（首轮验证准确率低至 5.9%）。本文提出 $p_{init} = 1.0$ 的初始化策略——训练初期等效于 GAP（与基线一致），训练中 p 自动增长聚焦判别性区域——解决了收敛问题，同时保留了 GeM 的优势。最终 Macro F1 提升 3.0%，Lupus 类别 F1 提升 17.6%。

创新点二：GRN + GeM 协同机制

ConvNeXt V2 的 GRN 层增强了特征多样性，GeM 在多样化的特征空间中更有效地聚焦判别性区域。两者的协同效应显著超越了各自独立贡献，在纹理/色素类疾病（Lupus、Bullous、Lichen）上尤为突出。

创新点三：可交互的多模态辅助诊断系统

构建了完整的 Web 应用，集成三个层面的智能辅助：（1）高精度图像分类；（2）Grad-CAM 注意力可视化（基线 vs 改进对比）；（3）大语言模型驱动的疾病咨询和报告生成，通过 SSE 流式传输实现实时交互。

创新点四：全面的消融实验与分析

系统设计了多组对比实验，覆盖了混淆矩阵、ROC 曲线、Per-Class 指标、训练曲线、注意力可视化等多个维度，为每个改进点的有效性提供了充分的实证支持。特别地，对 Skin Cancer 的 Recall-Precision 权衡进行了临床视角的深度分析。

6.2 应用推广

6.2.1 应用场景

表 6.1 应用场景说明

场景	说明
基层医疗机构	辅助全科医生进行皮肤病初步筛查，降低误诊和漏诊率
远程医疗	患者上传皮损照片，系统给出初步分类 + AI 建议，辅助远程问诊
医学教育	提供可视化的注意力热力图和疾病知识库，辅助医学生和住院医师学习
大规模筛查	社区/学校/工厂的批量皮肤癌/常见皮肤病筛查

6.2.2 推广路径

1. **开源社区**：代码已开源至 GitHub，提供完整训练/推理/部署文档。
2. **模型部署**：模型已导出为 ONNX 格式，可部署至边缘设备、移动端或云服务器。
3. **API 服务**：Flask 后端可直接作为 RESTful API 使用，方便集成至第三方系统。
4. **持续改进**：项目结构模块化，支持配置不同模型变体、数据集和 API 后端，便于后续扩展。

6.3 作品展望

6.3.1 短期改进（3-6 个月）

1. **多数据集融合训练**：结合 ISIC 2019、HAM10000 等多个公开数据集，提升模型在不同采集条件下的泛化能力。
2. **多任务学习**：在分类基础上添加病灶分割头，使用 Grad-CAM 作为弱监督信号，实现”诊断 + 定位”的联合输出。
3. **模型量化与加速**：对 ONNX 模型进行 INT8 量化，将推理时间压缩至 10ms 以下，满足移动端部署需求。

6.3.2 中长期规划（6-18 个月）

4. **多模态融合**：融合患者年龄、性别、病灶部位、病程等临床元数据，构建图像 + 结构化数据的多模态分类模型。
5. **纵向跟踪**：支持同一患者多次就诊的图像对比分析，评估病灶变化趋势，实现疾病进展监测。
6. **临床验证**：与皮肤科合作开展前瞻性临床验证，评估模型在实际临床环境中的表现，推进医疗器械认证。
7. **联邦学习**：在保护患者隐私的前提下，通过联邦学习框架联合多家医疗机构的数据，持续优化模型。

参考文献

- [1] Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. *CVPR 2022*.
- [2] Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I. S., & Xie, S. (2023). ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders. *CVPR 2023*.
- [3] Radenović, F., Tolias, G., & Chum, O. (2018). Fine-tuning CNN Image Retrieval with No Human Annotation. *IEEE TPAMI*, 41(7), 1655-1668.
- [4] Polyak, B. T., & Juditsky, A. B. (1992). Acceleration of Stochastic Approximation by Averaging. *SIAM J. Control Optim.*, 30(4), 838-855.
- [5] Selvaraju, R. R., et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. *ICCV 2017*.
- [6] Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *ICLR 2019*.
- [7] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR 2016*.